

AX팀 전달 자료 안내

이 폴더는 AX개발팀에 전달할 글도비 LLM 파이프라인 검토 자료입니다.

Markdown 문서를 바로 보기 어려운 경우에는 5_PDF판/ 폴더의 PDF 문서부터 보시면 됩니다. 같은 번호의 Markdown 문서와 PDF 문서는 같은 내용을 담고 있습니다.

검토 목적은 다음 세 가지입니다.

- LLM 파이프라인 구조 검토
- 비용 및 응답 지연 절감 가능 지점 검토
- 토큰 사용량 및 맥락 캐시 최적화 검토
- GCP/Vertex AI 직결 호출, 세션 메모리, 맥락 캐시 사용 방식 검토

먼저 읽을 순서

- 1_필수문서/00_한장_요약.md
- 1_필수문서/01_검토_요청서.md
- 1_필수문서/02_글도비_목적_및_전제.md
- 1_필수문서/06_현재_상태_주요_장애물_지원_요청.md
- 2_구성도/10_구성도_요약.pdf
- 1_필수문서/04_주요_데이터_흐름.md
- 1_필수문서/05_모델_비용_토큰_표면.md
- 4_추가자료/35_원본자료_전체공개_전달_가이드.md

PDF로 전달해야 하는 경우에는 위 순서와 같은 파일을 5_PDF판/ 폴더에서 열면 됩니다.

필요할 때 여는 자료

- 1_필수문서/00_한장_요약.md : 전체 검토 맥락을 한 장으로 요약한 진입 문서입니다.
- 1_필수문서/03_시스템_구성도.md : 구성도와 권한/장기기억 설명의 문서판입니다.
- 1_필수문서/06_현재_상태_주요_장애물_지원_요청.md : 현재 상태, 방향, 주요 장애물, AX팀 지원 요청 요약입니다.
- 2_구성도/11_구성도_상세.pdf : S0 -> S2 -> S3 -> S4 전체 상세 구성도입니다.
- 3_단계별_확대/*.pdf : S0, S2, S3, S4 각 단계별 확대 구성도입니다.

분석에 바로 도움이 되는 추가 자료

- 4_추가자료/30_비식별_진단_패킷_예시.md : 한 회차가 실제로 어떻게 비용과 시간을 쓰는지 보여주는 비식별 집계 예시입니다.
- 4_추가자료/31_회의용_질문_리스트.md : 미팅에서 바로 확인하고 싶은 질문 목록입니다.
- 4_추가자료/32_공유_가능_불가_자료.md : 공유 가능 자료와 기본 공유 제외 자료를 정리한 표입니다.
- 4_추가자료/33_Vertex_청구_대조_요청표.md : 로컬 추정 비용과 실제 Vertex 청구액 대조를 위한 요청표입니다.
- 4_추가자료/34_초안_최종후보본_품질_간극.md : Stage4 통과 초안과 독자용 최종 후보본 사이의 품질 간극 설명입니다.

- 4_추가자료/35_원본자료_전체공개_전달_가이드.md : 원본 프로젝트 폴더, DB, 로그를 AX팀 내부 검토용으로 열어 전달할 때의 범위와 제외 기준입니다.

원본 자료 공유 방향

기본 방향은 AX팀 내부 검토에 필요한 자료를 최대한 열어 전달하는 것입니다. 원고, 원본 DB, LLM 호출 장부, 캐시 장부, 로그는 비용/지연/연속성 병목을 보는 데 중요하므로 공유 후보에 포함합니다.

다만 실제 비용이 나가거나 외부 계정에 접근할 수 있는 정보는 제외합니다. 예를 들면 `.env`, API key, OAuth token, service account JSON, billing console 접근 정보, 개인 계정 비밀번호, 배포/클라우드 인증 정보입니다.

검토 요청 핵심

- Stage4의 작가 에이전트 + 검토 에이전트 + 재시도 루프 비용/응답지연
- 최종 승인 맥락, 설계도 계보, 정착 상태의 권한 분리
- GCP/Vertex AI 직결 호출에서 맥락 캐시와 세션 메모리가 실제 비용/지연/품질에 주는 영향
- 맥락 캐시의 단순 적중률이 아니라 최신성 검증 기준
- 원고 전문 없이도 비용/토큰/응답지연을 분석할 수 있는 최소 관측 패킷