

AX팀 전달 자료 안내

이 폴더는 AX개발팀에 전달할 글도비 LLM 파이프라인 검토 자료입니다.

Markdown 문서를 바로 보기 어려운 경우에는 5_PDF판/ 폴더의 PDF 문서부터 보시면 됩니다. 같은 번호의 Markdown 문서와 PDF 문서는 같은 내용을 담고 있습니다.

검토 목적은 다음 다섯 가지입니다.

- LLM 파이프라인 구조 검토
- 비용 및 응답 지연 절감 가능 지점 검토
- 토큰 사용량 및 맥락 캐시 최적화 검토
- GCP/Vertex AI 직결 호출, 세션 메모리, 맥락 캐시 사용 방식 검토
- 비개발자 관점에서 MVP 범위, 적정 예산, 개발 기간, 실전 테스트 기준, 계속 투자 여부를 판단할 수 있는 의사결정 기준 수립 지원
- 안정화 종료 시점, 상업성 레이어/장기기억 검증 순서, 1차 개발 종료 조건을 포함한 로드맵 의사결정 보조

먼저 읽을 순서

- 1_필수문서/00_한장_요약.md
- 1_필수문서/01_검토_요청서.md
- 1_필수문서/02_글도비_목적_및_전제.md
- 1_필수문서/06_현재_상태_주요_장애물_지원_요청.md
- 2_구성도/10_구성도_요약.pdf
- 1_필수문서/04_주요_데이터_흐름.md
- 1_필수문서/05_모델_비용_토큰_표면.md
- 4_추가자료/35_원본자료_전체공개_전달_가이드.md
- 4_추가자료/36_비개발자_의사결정_지원_요청.md

PDF로 전달해야 하는 경우에는 위 순서와 같은 파일을 5_PDF판/ 폴더에서 열면 됩니다.

필요할 때 여는 자료

- 1_필수문서/00_한장_요약.md : 전체 검토 맥락을 한 장으로 요약한 진입 문서입니다.
- 1_필수문서/03_시스템_구성도.md : 구성도와 권한/장기기억 설명의 문서판입니다.
- 1_필수문서/06_현재_상태_주요_장애물_지원_요청.md : 현재 상태, 방향, 주요 장애물, AX팀 지원 요청 요약입니다.
- 2_구성도/11_구성도_상세.pdf : S0 -> S2 -> S3 -> S4 전체 상세 구성도입니다.
- 3_단계별_확대/*.pdf : S0, S2, S3, S4 각 단계별 확대 구성도입니다.

분석에 바로 도움이 되는 추가 자료

- 4_추가자료/30_비식별_진단_패킷_예시.md : 한 회차가 실제로 어떻게 비용과 시간을 쓰는지 보여주는 비식별 집계 예시입니다.
- 4_추가자료/31_회의용_질문_리스트.md : 미팅에서 바로 확인하고 싶은 질문 목록입니다.

- 4_추가자료/32_공유_가능_불가_자료.md : 공유 가능 자료와 기본 공유 제외 자료를 정리한 표입니다.
- 4_추가자료/33_Vertex_청구_대조_요청표.md : 로컬 추정 비용과 실제 Vertex 청구액 대조를 위한 요청표입니다.
- 4_추가자료/34_초안_최종후보본_품질_간극.md : Stage4 통과 초안과 독자용 최종 후보본 사이의 품질 간극 설명입니다.
- 4_추가자료/35_원본자료_전체공개_전달_가이드.md : 원본 프로젝트 폴더, DB, 로그를 AX팀 내부 검토용으로 열어 전달할 때의 범위와 제외 기준입니다.
- 4_추가자료/36_비개발자_의사결정_지원_요청.md : 비개발자가 예산, 기간, MVP, 실전 테스트 규모, 계속 투자 여부를 판단할 수 있도록 요청할 의사결정 보조 항목입니다.

원본 자료 공유 방향

기본 방향은 AX팀 내부 검토에 필요한 자료를 최대한 열어 전달하는 것입니다. 원고, 원본 DB, LLM 호출 장부, 캐시 장부, 로그는 비용/지연/연속성 병목을 보는 데 중요하므로 공유 후보에 포함합니다.

다만 실제 비용이 나가거나 외부 계정에 접근할 수 있는 정보는 제외합니다. 예를 들면 `.env`, API key, OAuth token, service account JSON, billing console 접근 정보, 개인 계정 비밀번호, 배포/클라우드 인증 정보입니다.

검토 요청 핵심

- Stage4의 작가 에이전트 + 검토 에이전트 + 재시도 루프 비용/응답지연
- 최종 승인 맥락, 설계도 계보, 정착 상태의 권한 분리
- GCP/Vertex AI 직결 호출에서 맥락 캐시와 세션 메모리가 실제 비용/지연/품질에 주는 영향
- 맥락 캐시의 단순 적중률이 아니라 최신성 검증 기준
- 원고 전문 없이도 비용/토큰/응답지연을 분석할 수 있는 최소 관측 패킷
- 현재 상태를 PoC, MVP, alpha, beta, 운영 준비 중 어디로 봐야 하는지에 대한 판단 기준
- 적정 예산, 개발 기간, 실전 테스트 규모, 계속 투자/축소/전환 기준을 비개발자가 이해할 수 있는 형태로 정리해 주는 의사결정 보조
- 추가 안정화/최적화 이후 상업성 레이어와 장기기억 검증을 어떤 순서로 진행해야 1차 개발 종료를 선언할 수 있는지에 대한 로드맵 검토