

AX팀 전달 자료 안내

이 폴더는 AX개발팀에 전달할 글도비 LLM 파이프라인 검토 자료입니다.

Markdown 문서를 바로 보기 어려운 경우에는 5_PDF판/ 폴더의 PDF 문서부터 보시면 됩니다. 같은 번호의 Markdown 문서와 PDF 문서는 같은 내용을 담고 있습니다.

검토 목적은 다음 일곱 가지입니다.

- LLM 파이프라인 구조 검토
- 비용 및 응답 지연 절감 가능 지점 검토
- 토큰 사용량 및 맥락 캐시 최적화 검토
- GCP/Vertex AI 직결 호출, 세션 메모리, 맥락 캐시 사용 방식 검토
- 비개발자 관점에서 MVP 범위, 적정 예산, 개발 기간, 실전 테스트 기준, 계속 투자 여부를 판단할 수 있는 의사결정 기준 수립 지원
- 안정화 종료 시점, 상업성 레이어/장기기억 검증 순서, 1차 개발 종료 조건을 포함한 로드맵 의사결정 보조
- 카나리아 실전 테스트를 단순 S2-S3-S4 재현성 확인이 아니라 장르가드, 스타일 레퍼런스, 장기기억/연속성, 상업성 보상 구조까지 함께 보는 검증으로 설계할 수 있는지 검토

먼저 읽을 순서

1. `1\_필수문서/00\_한장\_요약.md`
2. `1\_필수문서/01\_검토\_요청서.md`
3. `1\_필수문서/02\_글도비\_목적\_및\_전제.md`
4. `1\_필수문서/06\_현재\_상태\_주요\_장애물\_지원\_요청.md`
5. `2\_구성도/10\_구성도\_요약.pdf`
6. `1\_필수문서/04\_주요\_데이터\_흐름.md`
7. `1\_필수문서/05\_모델\_비용\_토큰\_표면.md`
8. `4\_추가자료/35\_원본자료\_전체공개\_전달\_가이드.md`
9. `4\_추가자료/36\_비개발자\_의사결정\_지원\_요청.md`

PDF로 전달해야 하는 경우에는 위 순서와 같은 파일을 5_PDF판/ 폴더에서 열면 됩니다.

필요할 때 여는 자료

- `1\_필수문서/00\_한장\_요약.md`: 전체 검토 맥락을 한 장으로 요약한 진입 문서입니다.
- `1\_필수문서/03\_시스템\_구성도.md`: 구성도와 권한/장기기억 설명의 문서판입니다.
- `1\_필수문서/06\_현재\_상태\_주요\_장애물\_지원\_요청.md`: 현재 상태, 방향, 주요 장애물, AX팀 지원 요청 요약입니다.
- `2\_구성도/11\_구성도\_상세.pdf`: S0 -> S2 -> S3 -> S4 전체 상세 구성도입니다.
- `3\_단계별\_확대/\*.pdf`: S0, S2, S3, S4 각 단계별 확대 구성도입니다.

분석에 바로 도움이 되는 추가 자료

- `4\_추가자료/30\_비식별\_진단\_패킷\_예시.md`: 한 회차가 실제로 어떻게 비용과 시간을 쓰는지 보여주는 비식별 집계 예시입니다.
- `4\_추가자료/31\_회의용\_질문\_리스트.md`: 미팅에서 바로 확인하고 싶은 질문 목록입니다.
- `4\_추가자료/32\_공유\_가능\_불가\_자료.md`: 공유 가능 자료와 기본 공유 제외 자료를 정리한 표입니다.
- `4\_추가자료/33\_Vertex\_청구\_대조\_요청표.md`: 로컬 추정 비용과 실제 Vertex 청구액 대조를 위한 요청표입니다.
- `4\_추가자료/34\_초안\_최종후보본\_품질\_간극.md`: Stage4 통과 초안과 독자용 최종 후보본 사이의 품질 간극 설명입니다.
- `4\_추가자료/35\_원본자료\_전체공개\_전달\_가이드.md`: 원본 프로젝트 폴더, DB, 로그를 AX팀 내부 검토용으로 열어 전달할 때의 범위와 제외 기준입니다.
- `4\_추가자료/36\_비개발자\_의사결정\_지원\_요청.md`: 비개발자가 예산, 기간, MVP, 실전 테스트 규모, 계속 투자 여부를 판단할 수 있도록 요청할 의사결정 보조 항목입니다.

원본 자료 공유 방향

기본 방향은 AX팀 내부 검토에 필요한 자료를 최대한 열어 전달하는 것입니다. 원고, 원본 DB, LLM 호출 장부, 캐시 장부, 로그는 비용/지연/연속성 병목을 보는 데 중요하므로 공유 후보에 포함합니다.

다만 실제 비용이 나가거나 외부 계정에 접근할 수 있는 정보는 제외합니다. 예를 들면 .env, API key, OAuth token, service account JSON, billing console 접근 정보, 개인 계정 비밀번호, 배포/클라우드 인증 정보입니다.

검토 요청 핵심

- Stage4의 작가 에이전트 + 검토 에이전트 + 재시도 루프 비용/응답지연
- 최종 승인 맥락, 설계도 계보, 정착 상태의 권한 분리
- GCP/Vertex AI 직결 호출에서 맥락 캐시와 세션 메모리가 실제 비용/지연/품질에 주는 영향
- 맥락 캐시의 단순 적중률이 아니라 최신성 검증 기준
- 원고 전문 없이도 비용/토큰/응답지연을 분석할 수 있는 최소 관측 패킷
- 카나리아 테스트에서 장르 약속, 문체/스타일 레퍼런스, 장기기억/연속성, 회차별 상업성 보상 구조를 함께 감리하는 기준
- 현재 상태를 PoC, MVP, alpha, beta, 운영 준비 중 어디로 봐야 하는지에 대한 판단 기준
- 적정 예산, 개발 기간, 실전 테스트 규모, 계속 투자/축소/전환 기준을 비개발자가 이해할 수 있는 형태로 정리해주는 의사결정 보조
- 추가 안정화/최적화 이후 상업성 레이어와 장기기억 검증을 어떤 순서로 진행해야 1차 개발 종료를 선언할 수 있는지에 대한 로드맵 검토