

글도비 AX 검토 한 장 요약

무엇을 검토받고 싶은가

글도비는 LLM으로 장기 연재형 웹소설 생산 공정을 자동화하려는 프로젝트입니다.

저희가 파악하는 범위에서는 LLM을 통한 장편 글쓰기, 특히 장기 연재형 웹소설 생산에는 아직 널리 합의된 표준 프로세스가 없습니다. 글도비는 상업 웹소설을 반복 가능한 장르 패턴, 대리만족, 캐릭터 관계, 회차별 보상 구조를 가진 패턴 구조로 보고, 이를 LLM 파이프라인으로 안정적으로 생산할 수 있는지 검증하고 있습니다.

이번에 AX팀에 요청드리고 싶은 것은 문장 표현 교정보다는 LLM 파이프라인 구조, 비용, 응답 지연, 토큰/캐시 최적화 검토, 그리고 비개발자 관점의 의사결정 기준 수립 지원입니다.

용어는 이렇게 읽어 주시면 됩니다

- S0/S2/S3/S4: 글도비 시스템의 생산 단계 이름입니다.
- 작가 에이전트(ChiefWriter): 원고 후보를 생성하는 LLM 역할입니다.
- 검토 에이전트(Director): 원고 후보를 평가하고 수정 방향을 판단하는 LLM 역할입니다.
- 통과(PASS): 해당 단계 기준을 통과했다는 뜻입니다. Stage4 통과가 곧 플랫폼 제출 최종본이라는 뜻은 아닙니다.
- 정착: 통과한 결과를 DB, 파일, 로그, 다음 회차 맥락에 일관되게 저장하는 과정입니다.
- 정보: 다음 단계가 기준으로 삼아야 하는 공식 원고나 사실 정보입니다.

현재 어디까지 왔나

- S0/S2/S3/S4 기준의 장기 콘텐츠 생산 파이프라인이 있습니다.
- S3는 회차 설계도를 만들고, S4는 원고 후보 생성, 검토 에이전트 평가, 재시도, 정착 처리를 수행합니다.
- 감독형 실행 기준으로 15화 초안 연쇄를 생성했습니다.
- 최종 승인 원고 접근자, 설계도 계보, 정착 증거, 품질 신호, 맥락 캐시 관측값이 있습니다.
- 현재 LLM 호출은 GCP/Vertex AI Gemini 경로로 직접 연결되어 있으며, 세션 메모리 envelope와 맥락 캐시 관측값을 보조 계층으로 기록합니다.
- 다만 현재 Stage4 통과(PASS)는 "상업 제출 후보본"이라기보다 "쓸 수 있는 초안"에 가깝습니다.

비개발자 관점에서 특히 필요한 도움

개발 실무자가 아닌 운영/기획 담당자 관점에서는, 현재 시스템을 기술적으로 어디까지 왔다고 봐야 하는지 판단하기 어렵습니다.

현재 자체 판단은 "1차 생산성 이슈는 어느 정도 닫혔고, 이후는 실전 테스트를 통해 디버깅, 안정화, 비용 통제 기준을 잡아가는 단계"입니다. 이 판단이 맞는지, 지금 상태를 PoC, MVP, alpha, beta, 운영 준비 중 어디에 놓아야 하는지 AX팀 관점의 의사결정 보조가 필요합니다.

또한 어느 정도 예산과 기간이 정상적인 개발/안정화 범위인지, 몇 회차/몇 작품의 실전 테스트를 통과해야 다음 단계로 넘어갈 수 있는지, 계속 투자할지 축소/전환할지 판단하는 지표가 필요합니다.

개인적인 판단으로는 현재 글도비는 안정화를 거의 끝내 가는 상태입니다. 추가 안정화/최적화 이후 상업성 레이어와 장기기억을 검증하면, 이 프로젝트는 1차적으로 개발 종료 단계에 들어갈 수 있다고 예상합니다. 이 로드맵 판단이 타당한지, 어떤 순서와 기준으로 종료 조건을 잡아야 하는지도 검토받고 싶습니다.

앞으로의 방향

현재는 S0 -> S2 -> S3 -> S4 구조입니다.

장기적으로는 S2가 새로 아크를 창작하는 역할을 줄이고, 재료/TR block을 S3가 읽을 수 있는 회차 패킷으로 정규화하는 역할로 바꾸려 합니다.

목표 방향은 아래와 같습니다.

현재: S0 -> S2 -> S3 -> S4

전환: S0/TR block -> S2 정규화기 -> S3 -> S4

장기: S2 정규화기를 S3 사전 점검으로 흡수

또한 Stage4 통과 이후에는 독자용 최종 후보본으로 승격시키는 별도 폴리싱 관문이 필요하다고 보고 있습니다.

현재 가장 큰 문제

1. Stage4 원고 생성과 검토 에이전트 평가가 반복되며 비용과 응답 지연이 커집니다.
2. 일부 충돌은 비싼 원고 생성과 검토를 이미 수행한 뒤에야 발견됩니다.
3. 최종 승인 원고, 회차 설계도, DB, 캐시, 세션 메모리 사이의 권한 경계가 복잡합니다.
4. 캐시와 세션 메모리가 실제로 비용/지연/품질을 개선하는지 아직 인과적으로 증명하지 못했습니다.
5. 15화 감독형 생성은 성공했지만, 완전 자동 장기 실행의 엄격 검증은 아직 별도입니다.
6. 로컬 추정 비용과 실제 Vertex 청구 데이터의 대조가 필요합니다.
7. 문체 예시 기반 주입과 구조 패턴 도너(성공 사례에서 뽑은 참고 패턴)를 일부 사용하고 있지만, 최종 후보본 품질까지 안정적으로 끌어올리기에는 더 체계화가 필요합니다.
8. 비개발자 관점에서는 현재 상태를 MVP로 봐도 되는지, 어느 정도 예산/기간/실전 테스트를 목표로 잡아야 하는지 판단 기준이 부족합니다.
9. 안정화 이후 상업성 레이어와 장기기억 검증을 어떤 순서로 배치해야 1차 개발 종료를 선언할 수 있는지 로드맵 판단이 필요합니다.

AX팀에 부탁드립니다 싶은 것

- Stage4에서 실제 비용/응답 지연이 누적되는 API 호출 구간 진단
- 역할별 모델 라우팅과 출력 토큰 예산 조정안 검토
- 비싼 원고 생성 전에 옮길 수 있는 조기 실패 탐지 항목 제안
- GCP/Vertex AI 직결 호출에서 맥락 캐시와 세션 메모리의 비용상 이득, 최신성 검증, 무효화 기준 검토
- 문체 예시와 구조 패턴 도너(참고 패턴)를 어디까지 프롬프트에 넣고, 어디부터 검색/캐시/후처리로 분리할지 검토
- 원고 전문이나 원문 프롬프트 없이도 진단 가능한 최소 비식별 관측 패킷 설계
- 장기 실행 검증과 비용 벤치마크를 어떤 형태로 설계해야 하는지에 대한 권고
- 현재 상태를 PoC/MVP/alpha/beta/운영 준비 중 어디로 볼지, 적정 예산과 개발 기간을 어떻게 잡을지, 실전 테스트 통과 기준을 어떻게 둘지에 대한 의사결정 보조
- 추가 안정화/최적화, 상업성 레이어, 장기기억 검증, 1차 개발 종료 선언까지의 로드맵 의사결정 보조

먼저 보면 좋은 자료

1. 01_검토_요청서.md

2. 02_글도비_목적_및_전제.md
3. 06_현재_상태_주요_장애물_지원_요청.md
4. ../2_구성도/10_구성도_요약.pdf
5. 04_주요_데이터_흐름.md
6. 05_모델_비용_토큰_표면.md

추가로 준비한 자료

- ../4_추가자료/30_비식별_진단_패킷_예시.md
- ../4_추가자료/31_회의용_질문_리스트.md
- ../4_추가자료/32_공유_가능_불가_자료.md
- ../4_추가자료/33_Vertex_청구_대조_요청표.md
- ../4_추가자료/34_초안_최종후보본_품질_간극.md
- ../4_추가자료/35_원본자료_전체공개_전달_가이드.md
- ../4_추가자료/36_비개발자_의사결정_지원_요청.md