

글도비 LLM 파이프라인 검토 요청

안녕하세요.

요청 주신 글도비 LLM 파이프라인 검토 자료를 전달드립니다.

이번 자료는 아래 세 가지 검토 목적에 맞춰 정리했습니다.

1. LLM 파이프라인 구조 검토
2. 비용 및 응답 지연 절감 가능 지점 검토
3. 토큰 사용량 및 맥락 캐시 최적화 검토

검토 전제는 다음과 같습니다. 저희가 파악하는 범위에서는 LLM을 통한 장편 글쓰기, 특히 장기 연재형 웹소설 생산에 대해 널리 합의된 표준 프로세스가 아직 없습니다. 글도비는 상업 웹소설을 반복 가능한 장르 패턴, 대리만족, 캐릭터 관계, 회차별 보상 구조를 가진 패턴 구조로 보고, 이를 LLM 파이프라인으로 안정적으로 생산할 수 있는지 검증하는 프로젝트입니다.

전달 자료 구성

필수 문서

- 00_한장_요약.md
- 전체 검토 맥락, 현재 위치, 핵심 문제, 지원 요청 한 장 요약
- 02_글도비_목적_및_전제.md
- 프로젝트 목적, 장편 글쓰기 표준 프로세스 부재, 자동화 대상 설명
- 03_시스템_구성도.md
- 시스템 구성, 단계별 역할, 권한 경계 설명
- 04_주요_데이터_흐름.md
- 주요 데이터 흐름과 Stage4 생성/검증/정착 흐름
- 05_모델_비용_토큰_표면.md
- 사용 모델, 호출 비용, 토큰, 캐시 관련 관측값
- 06_현재_상태_주요_장애물_지원_요청.md
- 현재 상태, 처리 방향, 주요 장애물, 우선 지원 요청 사항

구성도 PDF

- ../2_구성도/10_구성도_요약.pdf
- 빠르게 전체 구조를 보기 위한 요약 구성도
- ../2_구성도/11_구성도_상세.pdf
- S0 -> S2 -> S3 -> S4 기준축 상세 구성도

단계별 확대 PDF

- ../3_단계별_확대/20_S0_자료정리.pdf

- ../3_단계별_확대/21_S2_아키텍처.pdf
- ../3_단계별_확대/22_S3_회차설계도.pdf
- ../3_단계별_확대/23_S4_원고생성_검증_정착.pdf

추가 자료

- ../4_추가자료/30_비식별_진단_패킷_예시.md
- 한 회차의 비용/응답 지연/재시도 병목을 원고 없이 보여주는 비식별 예시
- ../4_추가자료/31_회의용_질문_리스트.md
- 미팅에서 바로 확인하고 싶은 질문 목록
- ../4_추가자료/32_공유_가능_불가_자료.md
- 공유 가능 자료와 기본 공유 제외 자료
- ../4_추가자료/33_Vertex_청구_대조_요청표.md
- 실제 Vertex 청구액과 로컬 추정 비용 대조 요청표
- ../4_추가자료/34_초안_최종후보본_품질_간극.md
- Stage4 통과 초안과 최종 후보본 사이의 품질 간극

주요 검토 요청 사항

현재 가장 중점적으로 검토받고 싶은 부분은 Stage4 원고 생성 이후의 비용과 응답 지연입니다.

특히 아래 항목에 대한 의견을 부탁드립니다.

- 작가 에이전트와 검토 에이전트 호출이 반복될 때 비용이 누적되는 구조
- 비싼 원고 생성 호출 전에 더 앞단으로 옮길 수 있는 검증 항목
- 역할별 모델 라우팅과 출력 토큰 예산 분리 가능성
- 맥락 캐시 사용 시 필요한 최신성 검증 기준
- 최종 승인 원고, 회차 설계도, 장기기억 계층 사이의 권한 경계
- 원고 전문 없이 비용/지연 분석에 필요한 최소 관측 데이터

제출 범위

이번 공유 자료에는 시스템 구조, 데이터 흐름, 모델/토큰/비용 관측값, 구성도만 포함했습니다.

아래 항목은 기본 공유 범위에서 제외했습니다.

- 원문 프롬프트
- 원고 전문
- 원본 로컬 DB
- 비식별화되지 않은 LLM 입출력 로그
- 로컬 환경 설정 또는 인증 정보

필요하신 경우, 원고 전문을 제외한 비식별 집계 데이터나 제한된 샘플 형태로 추가 자료를 준비하겠습니다.

감사합니다.