

글도비 LLM 파이프라인 검토 요청

안녕하세요.

요청 주신 글도비 LLM 파이프라인 검토 자료를 전달드립니다.

이번 자료는 아래 다섯 가지 검토 목적에 맞춰 정리했습니다.

1. LLM 파이프라인 구조 검토
2. 비용 및 응답 지연 절감 가능 지점 검토
3. 토큰 사용량 및 맥락 캐시 최적화 검토
4. GCP/Vertex AI 직결 호출, 세션 메모리, 맥락 캐시 사용 방식 검토
5. 비개발자 관점의 MVP 범위, 적정 예산, 개발 기간, 실전 테스트 기준, 계속 투자 여부 판단을 위한 의사결정 보조
6. 안정화 종료 시점, 상업성 레이어/장기기억 검증 순서, 1차 개발 종료 조건을 포함한 로드맵 의사결정 보조

검토 전제는 다음과 같습니다. 저희가 파악하는 범위에서는 LLM을 통한 장편 글쓰기, 특히 장기 연재형 웹소설 생산에 대해 널리 합의된 표준 프로세스가 아직 없습니다. 글도비는 상업 웹소설을 반복 가능한 장르 패턴, 대리만족, 캐릭터 관계, 회차별 보상 구조를 가진 패턴 구조로 보고, 이를 LLM 파이프라인으로 안정적으로 생산할 수 있는지 검증하는 프로젝트입니다.

추가로, 개발 실무자가 아닌 운영/기획 담당자 관점에서는 기술 병목 진단뿐 아니라 의사결정 기준 수립도 필요합니다. 현재 자체 판단은 "1차 생산성 이슈는 어느 정도 닫혔고, 이후는 실전 테스트 기반 디버깅/안정화 단계"입니다. 이 판단이 맞는지, 현재 상태를 PoC/MVP/alpha/beta/운영 준비 중 어디로 봐야 하는지, 어느 정도 예산과 기간을 정상 범위로 봐야 하는지 검토 부탁드립니다.

개인적인 판단으로는 현재 글도비는 안정화를 거의 끝내 가는 상태입니다. 추가 안정화/최적화 이후 상업성 레이어와 장기기억 검증을 통과하면 1차 개발 종료 단계에 들어갈 수 있다고 예상합니다. 이 로드맵 판단이 타당한지, AX팀 관점에서 종료 조건과 다음 단계 순서를 어떻게 잡아야 하는지도 함께 검토 부탁드립니다.

전달 자료 구성

필수 문서

- 00_한장_요약.md
 - 전체 검토 맥락, 현재 위치, 핵심 문제, 지원 요청 한 장 요약
- 02_글도비_목적_및_전제.md
 - 프로젝트 목적, 장편 글쓰기 표준 프로세스 부재, 자동화 대상 설명
- 03_시스템_구성도.md
 - 시스템 구성, 단계별 역할, 권한 경계 설명
- 04_주요_데이터_흐름.md
 - 주요 데이터 흐름과 Stage4 생성/검증/정착 흐름
- 05_모델_비용_토큰_표면.md
 - 사용 모델, 호출 비용, 토큰, 캐시 관련 관측값
- 06_현재_상태_주요_장애물_지원_요청.md
 - 현재 상태, 처리 방향, 주요 장애물, 우선 지원 요청 사항

구성도 PDF

- ../2_구성도/10_구성도_요약.pdf
 - 빠르게 전체 구조를 보기 위한 요약 구성도
- ../2_구성도/11_구성도_상세.pdf
 - S0 -> S2 -> S3 -> S4 기준축 상세 구성도

단계별 확대 PDF

- ../3_단계별_확대/20_S0_자료정리.pdf
- ../3_단계별_확대/21_S2_아키텍처.pdf
- ../3_단계별_확대/22_S3_회차설계도.pdf
- ../3_단계별_확대/23_S4_원고생성_검증_정착.pdf

추가 자료

- ../4_추가자료/30_비식별_진단_패킷_예시.md
 - 한 회차의 비용/응답 지연/재시도 병목을 원고 없이 보여주는 비식별 예시
- ../4_추가자료/31_회의용_질문_리스트.md
 - 미팅에서 바로 확인하고 싶은 질문 목록
- ../4_추가자료/32_공유_가능_불가_자료.md
 - 공유 가능 자료와 기본 공유 제외 자료
- ../4_추가자료/33_Vertex_청구_대조_요청표.md
 - 실제 Vertex 청구액과 로컬 추정 비용 대조 요청표
- ../4_추가자료/34_초안_최종후보본_품질_간극.md
 - Stage4 통과 초안과 최종 후보본 사이의 품질 간극
- ../4_추가자료/35_원본자료_전체공개_전달_가이드.md
 - 원본 프로젝트 폴더, DB, 로그를 AX팀 내부 검토용으로 열어 전달할 때의 범위와 제외 기준
- ../4_추가자료/36_비개발자_의사결정_지원_요청.md
 - 비개발자 관점의 예산, 기간, MVP, 실전 테스트, 계속 투자 판단 기준 요청

주요 검토 요청 사항

현재 가장 중점적으로 검토받고 싶은 부분은 Stage4 원고 생성 이후의 비용과 응답 지연, 그리고 다음 투자/개발 단계를 정하기 위한 판단 기준입니다.

특히 아래 항목에 대한 의견을 부탁드립니다.

- 작가 에이전트와 검토 에이전트 호출이 반복될 때 비용이 누적되는 구조
- 비싼 원고 생성 호출 전에 더 앞단으로 옮길 수 있는 검증 항목
- 역할별 모델 라우팅과 출력 토큰 예산 분리 가능성
- 맥락 캐시 사용 시 필요한 최신성 검증 기준
- 최종 승인 원고, 회차 설계도, 장기기억 계층 사이의 권한 경계
- 원고 전문 없이 비용/지연 분석에 필요한 최소 관측 데이터

- 현재 상태를 PoC, MVP, alpha, beta, 운영 준비 중 어디로 봐야 하는지
- 적정 예산, 개발 기간, 안정화 기간, 실전 테스트 규모, 계속 투자/축소/전환 기준
- 비개발자가 매주 확인할 수 있는 비용/품질/속도 대시보드 항목
- 추가 안정화/최적화, 상업성 레이어 검증, 장기기억 검증, 1차 개발 종료 선언을 어떤 순서와 기준으로 배치해야 하는지

제출 범위

이번 공유 자료에는 시스템 구조, 데이터 흐름, 모델/토큰/비용 관측값, 구성도, 현재 상태/장애물/지원 요청, 원본 자료 공유 가이드를 포함했습니다.

기본 방향은 AX팀 내부 기술 검토에 필요한 자료를 가능한 한 열어 전달하는 것입니다. 필요 시 원본 프로젝트 폴더, 원본 로컬 DB, 실행 로그, 원고 샘플, 프롬프트/응답 근거를 검토 후보에 포함할 수 있습니다.

다만 아래처럼 실제 비용 발생이나 계정 접근이 가능한 자료는 제외합니다.

- `.env`
- API key, secret, bearer token
- OAuth refresh/access token
- GCP service account JSON
- billing console 접근 정보
- 개인 계정 비밀번호
- 배포/운영 credential

세부 기준은 `../4_추가자료/32_공유_가능_불가_자료.md` 와 `../4_추가자료/35_원본자료_전체공개_전달_가이드.md` 에 정리했습니다.

감사합니다.