

AX 검토용 모델 / 비용 / 토큰 표면

기준일: 2026-04-30

목적

이 문서는 AX개발팀 검토를 위해 모델 라우팅, Stage4 비용/토큰 신호, 맥락 캐시 증거, 최적화 질문을 요약합니다. 아래 비용 수치는 현재 로컬 Stage4 증거 스냅샷에서 산출한 런타임 추정치입니다. 실제 클라우드 청구 원장이 아니므로, AX 검토 시 Vertex billing 기준으로 재확인이 필요합니다.

현재 모델 라우팅 요약

현재 조사 증거 기준 관측값입니다.

표면	현재 경로 / 동작
주 생산 모델 계열	Vertex AI Gemini 경로
Pro 중심 모델	vertexai:gemini-3.1-pro-preview
실패 시 대체 경로	vertexai:gemini-3.1-pro-preview -> vertexai:gemini-2.5-pro -> vertexai:gemini-2.5-flash
Stage4 주요 역할	chief_writer , director
최대 출력 토큰 설정	api.max_output_tokens: 65536
API 타임아웃 설정	api.timeout: 300
검토 에이전트 재시도 한도	retry.director_max_attempts: 10
품질 관문 점수	scoring.quality_gate_score: 90

AX팀에서는 실제 청구액, 현재 모델 사용 가능 여부, 캐시 가격 정책, preview 모델 가격/쿼터 동작을 Vertex billing data 기준으로 확인해 주시면 좋겠습니다.

Stage4 로컬 비용 스냅샷

로컬 llm_calls 기준 Stage4 읽기 전용 스냅샷입니다.

호출 수	입력 토큰	출력 토큰	캐시 토큰	추정 비용 USD	평균 소요 ms
653	13,402,078	1,566,917	6,987,784	24.404141	48,819.6

주요 역할/모델:

agent	model	호출 수	총 토큰	추정 비용 USD	평균 ms	비성공
chief_writer	vertexai:gemini-3.1-pro-preview	269	8,878,731	16.017692	82,647.4	17
director	vertexai:gemini-3.1-pro-preview	271	4,939,301	5.549227	20,547.3	12
chief_writer	vertexai:gemini-2.5-pro	23	368,672	1.637426	64,770.3	0
director	vertexai:gemini-2.5-pro	44	490,294	0.752089	27,352.6	0

해석:

- Stage4 비용은 작가 에이전트(ChiefWriter)와 검토 에이전트(Director)가 지배합니다.
- 재시도-heavy 회차는 작가 에이전트와 검토 에이전트 호출을 동시에 증폭시킵니다.
- 모델만 바꾸는 최적화는 충분하지 않을 가능성이 큼니다. 재시도 경로, 선택 후 점검 시점, 캐시 정책, 출력 예산을 함께 봐야 합니다.

맥락 캐시 스냅샷

Stage4 context_cache_attempts 기준 관측 분포입니다.

agent	캐시 유형	결과	횟수	내용 글자 수
chief_writer	manuscript	created	35	3,742,256
director	director_ensemble	created	22	1,685,173
director	director_ensemble	skipped	14	420,016
director	manuscript	skipped	14	384,157
director	director_ensemble	hit	7	506,020
director	blueprint	skipped	2	4,128
chief_writer	manuscript	skipped	1	39,526

해석:

- 캐시는 존재하고 관측 가능합니다.
- 캐시 적중률과 최신성 정책만으로 비용/응답 지연 문제가 해결됐다고 말하기는 아직 어렵습니다.
- 현재 캐시 증거는 오래된 소스 억제보다는 사용량/계산 근거 쪽에 가깝습니다.

AX 검토용 최적화 가설

H1. 역할별 출력/토큰 예산 분리

현재 전역 최대 출력 토큰이 큼니다. 모든 역할이 같은 예산을 가져야 하는지 검토가 필요합니다.

- 작가 에이전트 후보 원고 생성

- 검토 에이전트 평가
- 선택 후 충돌 분석
- 부분 수정(PASS_WITH_FIX)
- 전체 재작성 재시도
- Stage3 설계도 재생성

H2. 더 이른 저비용 충돌 탐지

선택 후 충돌은 원고 생성과 검토 뒤에 발생하므로 비쌉니다.

검토 지점:

- 일부 연속성/계산 점검을 전체 후보 원고 생성 전에 수행할 수 있는지
- 충돌 하위 유형별로 결정론적 점검 또는 짧은 LLM 점검으로 보낼 수 있는지
- 전체 재작성을 고확신 의미 충돌에만 제한할 수 있는지

H3. 후보 원고 생성 전략

현재 Stage4는 작가 에이전트 후보 원고 생성에 많은 비용을 쓸 수 있습니다.

검토 지점:

- 다중 후보 1회 호출과 여러 작가 호출 중 무엇이 유리한지
- 1차 후보에는 더 작은 모델을 쓰고 최종 후보/재작성에 pro 모델을 예약할 수 있는지
- 회차 위험도/상태에 따라 후보군 폭을 적응형으로 줄일 수 있는지

H4. 캐시 정책과 계보

캐시 계보에 아래 식별 지문이 필요한지 검토가 필요합니다.

- 제공사(provider)
- model
- 프롬프트/내용 해시
- 실행 id
- 승인 원고 해시
- DB 설계도 계보 해시
- 산출물 버전
- 상위 stage 상태 해시
- 작품/재료 버전

목표는 단순 캐시 적중률이 아닙니다. 목표는 오래된 맥락을 재유입하지 않으면서 비용상 이득이 있는 캐시 재사용입니다.

H5. 캐시/세션 인과 벤치마크

캐시/세션 벤치마크에서는 해당 변경이 아래 항목을 줄이는지 측정해야 합니다.

- 통과(PASS)까지 필요한 재시도 수
- 선택 후 충돌 재발
- 반복 설명/프롬프트 부하
- 승인 회차당 응답지연

- 승인 회차당 추정 비용
- 연속성 실패 범주

AX팀 청구 확인 질문

1. vertexai:gemini-3.1-pro-preview 의 실제 Vertex 청구 기준 단가는 무엇인가?
2. active model family에서 캐시 입력 토큰은 일반 입력 토큰과 다르게 과금되는가?
3. 맥락 캐시 생성, 읽기, 저장 비용은 어떻게 계산되는가?
4. thinking/reasoning 토큰이 별도로 노출되고 과금되는가?
5. 라우팅/캐싱 전에 count_tokens 를 사용하는 것이 비용상 유리한가?
6. 재시도/연속생성 응답지연을 원 API 응답지연과 분리해 볼 수 있는 관측값이 있는가?
7. preview 모델 가격/쿼터가 정식 모델 가격/쿼터와 다른가?

먼저 최적화하지 말아야 할 것

Pro에서 Flash로 일괄 다운그레이드하는 방식은 먼저 권장하지 않습니다.

이유:

- 현재 품질/연속성 관문 자체가 재시도-heavy입니다.
- 싼 모델이 재시도 루프를 늘리면 비용 절감이 사라질 수 있습니다.
- 전역 모델 변경보다 역할별 라우팅이 더 안전합니다.

제공사 메모리를 정본처럼 취급하는 것도 권장하지 않습니다.

이유:

- 제공사 메모리/캐시는 맥락 비용을 낮출 수 있습니다.
- 하지만 최신성과 권한 라벨이 명확하지 않으면 오래되었거나 오염된 맥락을 보존할 수 있습니다.

권장 벤치마크 형태

캐시/세션 검증용 최소 벤치마크 패킷입니다.

지표	필수 여부
승인 회차 수	필수
통과(PASS) 전 재시도 수	필수
하위 유형별 선택 후 충돌 수	필수
역할/모델별 호출 수	필수
입력/출력/캐시 토큰	필수
추정 비용과 벽시계 시간	필수
캐시 생성/적중/건너뛸/오류	필수
최종 승인 맥락 상태	필수

지표	필수 여부
설계도 계보 출처/해시	필수
연속성 카나리아 상태	필수
비식별화된 산출물 진실 샘플	권장