

현재 상태, 주요 장애물, 지원 요청

이 문서는 글도비의 현재 위치와 앞으로 가려는 방향, 그리고 AX개발팀에 구체적으로 검토받고 싶은 지점을 요약합니다.

한 줄 요약

글도비는 장기연재 원고를 15화까지 생산하는 데 성공했지만, 아직 "상업 제출 후보본을 안정적으로, 저비용으로, 재현 가능하게 생산한다"고 말하기에는 부족합니다.

현재 가장 큰 문제는 원고 생성 자체가 아니라 아래 네 가지입니다.

1. Stage4 원고 생성과 검토 루프의 비용과 응답 지연
2. 최종 승인 원고, 회차 설계도, 장기기억 계층 사이의 권한 경계
3. 맥락 캐시와 세션 메모리가 실제로 비용과 재시도를 줄이는지에 대한 검증 부족
4. Stage4 PASS 이후 독자용 최종 후보본으로 승격시키는 폴리싱 관문 부족

왜 필요한가

저희가 파악하는 범위에서는 LLM을 통한 장편 글쓰기, 특히 장기 연재형 웹소설 생산에는 아직 널리 합의된 표준 프로세스가 없습니다.

상업 웹소설은 문학 일반이라기보다 반복 가능한 장르 패턴, 대리만족, 캐릭터 관계, 사건 보상, 회차별 후킹이 결합된 패턴 구조에 가깝습니다. 이 패턴성 때문에 LLM이 생산성을 크게 높일 수 있지만, 장편에서는 이전 회차 기억, 설정 일관성, 캐릭터 상태, 비용, 재시도, 최종 품질 검증이 동시에 문제가 됩니다.

글도비는 이 때문에 "LLM에게 소설을 한 번에 쓰게 하는 도구"가 아니라 "장기 콘텐츠 생산 공정을 LLM으로 분해, 생성, 검증, 정착시키는 시스템"을 목표로 합니다.

현재 위치

된 것

- S0/S2/S3/S4 기준의 장기 콘텐츠 생산 파이프라인이 존재합니다.
- Stage3에서 회차 설계도를 만들고, Stage4에서 원고 후보를 생성한 뒤 검토 에이전트(Director)가 평가합니다.
- 감독형 실행 기준으로 15화 초안 연쇄를 생성했습니다.
- 최종 승인 원고 접근자, 설계도 계보, Stage4 정착 처리, 품질 신호, 맥락 캐시 관측값이 존재합니다.
- 최근 보강으로 Stage4 구조 수리 증거, 최종 승인 맥락, 설계도 계보, 원고 산출물 진실 명세, 실행 상태 분류가 추가되었습니다.

아직 안 된 것

- 장기 실행을 완전히 통과한 엄격 검증은 아직 없습니다.
- 맥락 캐시와 세션 메모리가 비용/지연/품질에 얼마나 기여했는지 인과적으로 증명하지 못했습니다.
- Stage4의 통과(PASS)는 현재 "쓸 수 있는 초안"에 가깝고, 플랫폼 제출 후보본까지의 마지막 독자용 품질문은 별도입니다.

- 일부 실패는 비싼 원고 생성과 검토를 이미 수행한 뒤에야 발견됩니다.
- 문체 예시 기반 주입과 구조 패턴 도너(성공 사례에서 뽑은 참고 패턴)를 일부 사용하고 있지만, 최종 후보본 품질을 안정적으로 보장하기에는 더 체계화가 필요합니다.
- 실제 클라우드 청구액과 로컬 추정 비용 사이의 대조가 아직 필요합니다.

앞으로의 방향

1. 핵심 기준축은 S0/S2/S3/S4로 설명

OneStop, FrontierLag 같은 실행 제어 기능은 특수 기능으로 보고, AX팀 검토에서는 아래 기준축으로 설명합니다.

S0 재료 정리
-> S2 아크/페이싱 정규화
-> S3 회차 설계도
-> S4 원고 생성/검증/정착

2. S2는 장기적으로 줄이는 방향

현재 검토 중인 큰 방향은 기존 S2 = LLM이 새로 아크를 기획하는 단계 를 줄이는 것입니다.

재료 단계에서 이미 TR block 단위 페이싱이 정해져 있다면, S2가 다시 페이싱을 결정하는 것은 중복입니다. 따라서 장기적으로는 S2를 "창작 단계"가 아니라 "block을 S3가 읽을 수 있는 회차 패킷으로 정규화하는 단계"로 바꾸는 방향을 검토합니다.

목표 방향은 아래에 가깝습니다.

현재: S0 -> S2 -> S3 -> S4
전환: S0/TR block -> S2 정규화기 -> S3 -> S4
장기: S2 정규화기를 S3 사전 점검으로 흡수

즉 사용자 관점에서는 3단계 생산 공정을 2단계에 가깝게 단순화하고, 시스템 안에서는 검증 가능한 정규화/전처리 단계만 남기는 방향입니다.

3. Stage4 통과와 최종 제출 후보본을 분리

Stage4 통과(PASS)는 "서사와 설정을 갖춘 사용 가능한 초안"으로 유지합니다.

다만 독자가 실제로 보는 플랫폼 제출 후보본은 별도 승격 관문을 통과해야 합니다.

Stage4 통과(PASS)
-> 독자용 폴리싱
-> 모바일 가독성 점검
-> 장르별 AI 티/과잉 표현 점검
-> 최종 내보내기

이 분리는 생성 파이프라인과 폴리싱 파이프라인을 섞지 않기 위한 것입니다.

4. 모델 다운그레이드보다 역할별 비용 구조를 먼저 본다

현재 병목은 단순히 "비싼 모델을 쓴다"가 아닙니다.

비싼 원고 생성, 검토 에이전트 평가, 선택 후 충돌 점검, 재시도, 전체 재작성 경로가 같이 비용을 키웁니다. 따라서 일괄 모델 변경보다 역할별 모델 라우팅, 출력 토큰 예산, 조기 충돌 탐지, 캐시 정책을 함께 봐야 합니다.

5. 문체 예시와 구조 패턴 도너를 더 체계화한다

현재도 일부 문제는 문체 예시 기반 주입, 즉 few-shot에 가까운 방식과 구조 패턴 도너(성공 사례에서 뽑은 참고 패턴)로 완화하고 있습니다.

다만 아직은 어느 정보를 매번 프롬프트에 넣고, 어느 정보를 검색/캐시로 재사용하며, 어느 문제를 Stage4 이후 독자용 폴리싱 관문으로 넘길지 명확한 비용 기준이 부족합니다.

따라서 문체 예시, 성공 구조 패턴, 장르별 보상 리듬을 더 잘 쓰되, 토큰 비용과 재시도 증가를 함께 통제하는 방향이 필요합니다.

핵심 문제

현재 문제는 "LLM이 글을 전혀 못 쓴다"가 아닙니다. 오히려 초안 생산은 가능해졌습니다. 문제는 이 초안을 장기 연재 공정에서 안정적으로 반복 생산하고, 비용을 예측 가능하게 만들고, 최종 독자용 후보본으로 승격시키는 과정입니다.

주요 장애물	현재 증상	영향
Stage4 수렴 비용	원고 생성, 검토 에이전트 평가, 선택 후 충돌, 재작성 루프가 반복됨	비용과 응답 지연이 커지고 실행 시간이 예측 어려움
낮은 충돌 탐지	일부 문제는 원고 생성과 검토 비용을 낸 뒤에 발견됨	비싼 실패가 반복됨
권한 계층 복잡도	최종 승인 원고, 설계도, DB, 캐시, 세션 메모리가 각각 다른 역할을 가짐	운영자가 "무엇이 정보인가"를 해석하기 어려움
캐시/세션 효과 미검증	캐시 생성과 적중은 관측되지만 품질/비용 개선의 인과가 아직 약함	캐시를 늘려도 실제 절감인지 판단하기 어려움
문체/구조 패턴 주입의 체계 부족	few-shot식 문체 예시와 구조 패턴 도너(참고 패턴)를 일부 쓰지만 비용/효과 기준이 약함	품질 보강이 토큰 증가와 재시도로 이어질 수 있음
장기 실행 검증 부족	15화 감독형 생성은 성공했지만, 완전 자동 장기 실행 성공 증거는 별도	실사용 신뢰 기준 주장에 제한이 있음
최종 후보본 품질문 부족	Stage4 통과 초안이 모바일 독자용 기준까지 자동 승격되지는 않음	사람 손 폴리싱이 남음
비용 관측값의 청구 대조 부족	로컬 추정 비용은 있으나 실제 Vertex 청구 데이터와 대조 필요	최적화 우선순위가 왜곡될 수 있음

AX팀에 도움 요청드립니다

1. 비용/응답 지연 구조 진단

- Stage4에서 실제로 병목이 되는 API 호출 구간이 어디인지 확인
- 원 API 응답 지연, 재시도 지연, 연속 생성 지연, 캐시 생성/조회 지연을 분리할 관측값 제안
- 호출 단위, 회차 단위, 승인 원고 단위의 비용 집계 방법 제안

2. 모델 라우팅과 토큰 예산 검토

- 작가 에이전트(ChiefWriter), 검토 에이전트(Director), 선택 후 충돌 분석, 부분 수정, 전체 재작성에 같은 모델과 같은 출력 예산을 쓰는 것이 적절한지 검토
- 1차 후보 생성에는 더 작은 모델을 쓰고 최종 후보나 전체 재작성에만 상위 모델을 쓰는 전략 검토
- `max_output_tokens`, `count_tokens`, preview 모델 가격/쿼터, thinking/reasoning 토큰 노출 여부 확인

3. 조기 실패 탐지 설계

- 비싼 원고 생성 전으로 옮길 수 있는 검증 항목 제안
- Stage3 설계도 단계에서 잡아야 할 충돌과 Stage4 원고 단계에서 잡아야 할 충돌 분리
- 선택 후 충돌이 항상 전체 재작성으로 가야 하는지, 하위 유형별로 더 싼 경로가 가능한지 검토

4. 캐시/세션 메모리 검증

- 맥락 캐시가 비용상 실제 이득인지 청구 기준으로 확인
- 캐시 계보에 필요한 지문 제안
- 오래된 맥락 재사용을 막기 위한 무효화 기준 제안
- 세션 메모리를 정본이 아닌 보조 증거로 쓸 때 필요한 안전장치 검토

5. 최소 비식별 진단 패킷 설계

원고 전문이나 원문 프롬프트 없이도 AX팀이 진단할 수 있는 최소 패킷을 함께 정하고 싶습니다.

후보 항목은 아래입니다.

- 회차별 시도 수
- 역할/모델별 호출 수
- 입력/출력/캐시 토큰
- 추정 비용과 실제 청구액 대조값
- 캐시 생성/적중/건너뛴/오류
- 실패 범주와 재시도 경로
- 최종 승인 맥락 상태
- 설계도 계보 해시/출처 상태
- 비식별화된 산출물 진실 샘플

6. 문체 예시 / 구조 패턴 도너 운영 방식 검토

- 문체 예시를 프롬프트에 직접 넣는 방식과 검색/캐시로 넣는 방식 중 어떤 쪽이 비용상 유리한지 검토
- 구조 패턴 도너를 Stage3 설계도 단계에 넣을지, Stage4 원고 생성 단계에 넣을지 검토
- 도너를 늘렸을 때 초기 품질이 올라가는지, 아니면 토큰과 응답 지연만 늘어나는지 비교할 벤치마크 설계
- 최종 후보본 폴리싱 관문에서 문체 예시를 더 작은 모델로 처리할 수 있는지 검토

특히 긴급하게 봐 주셨으면 하는 것

아래 항목은 단순 개선보다 우선 지원을 요청드리고 싶은 부분입니다.

1. Stage4의 비싼 실패 루프를 어디서 끊어야 하는지
2. 현재 모델/토큰/캐시 정책이 실제 Vertex 청구 기준으로 어떤 비용 구조를 만드는지
3. 캐시와 세션 메모리가 오래된 맥락을 보존하는 위험을 어떻게 막아야 하는지

4. 장기 실행 검증과 비용 벤치마크를 어떤 형태로 설계해야 실사용 신뢰 기준 주장에 충분한지
5. 원고 전문 없이도 AX팀이 진단 가능한 최소 비식별 추적 자료가 무엇인지
6. 문체 예시와 구조 패턴 도너를 품질 개선에 쓰면서도 토큰/지연을 통제하려면 어떤 구조가 좋은지

AX팀 검토 후 기대 산출물

- 비용과 응답 지연의 우선 병목 순위
- 역할별 모델 라우팅/토큰 예산 조정안
- 캐시/세션 메모리 사용 기준과 무효화 기준
- Stage4 재시도 루프를 줄이기 위한 구조 개선안
- 원고 전문 없이 공유 가능한 진단 패킷 형식
- 문체 예시와 구조 패턴 도너의 비용 대비 효과를 검증할 벤치마크 설계
- 장기 실행 검증과 벤치마크 설계에 대한 권고안