

비식별 진단 패킷 예시

이 문서는 AX팀이 실제 병목을 빠르게 파악할 수 있도록, 한 회차의 Stage4 실행을 비식별 집계값으로 요약한 예시입니다.

원고 전문, 원문 프롬프트, LLM 원문 응답, 원본 DB는 포함하지 않았습니다.

샘플 회차 A

아래 값은 실제 카나리아 실행의 한 회차를 비식별화해 집계한 예시입니다.

항목	값
Stage4 시도 수	5
거절 시도 수	4
최종 통과 시도 수	1
Stage4 시도 누적 시간	약 45.0분
LLM 호출 수	90
입력 토큰	1,868,217
출력 토큰	185,072
캐시 토큰	851,333
로컬 추정 비용	약 USD 3.23
비성공 LLM 호출	13

역할별 호출 집계

역할	모델	호출 수	입력 토큰	출력 토큰	캐시 토큰	로컬 추정 비용 USD	평균 소요
작가 에이전트	vertexai:gemini-3.1-pro-pre view	41	1,155,179	175,650	765,413	2.34	72.1초
검토 에이전트	vertexai:gemini-3.1-pro-pre view	46	695,267	7,663	85,920	0.85	17.0초
관리/보조	vertexai:gemini-3.1-pro-pre view	2	13,136	1,722	0	0.03	53.4초
상태 추출	vertexai:gemini-3.1-pro-pre view	1	4,635	37	0	0.01	10.5초

시도별 결과

시도	결과	점수	실패 범주	주 실패 계층	처리 방향	소요
1	거절	50	제약 위반	검토 에이전트 품질	부분 수정	8.9분
2	거절	96	선택 후 충돌	후단 관문	전체 재작성	5.4분
3	거절	50	제약 위반	검토 에이전트 품질	부분 수정	7.7분
4	거절	43	논리 오류	검토 에이전트 품질	부분 수정	11.9분
5	통과	96	없음	없음	통과 정착	11.1분

캐시 관측값

역할	캐시 유형	결과	횟수	대상 글자 수
작가 에이전트	원고 맥락	생성	5	595,074
검토 에이전트	후보 묶음	생성	5	348,677
검토 에이전트	원고 맥락	건너뛰	1	36,383

이 예시에서 보이는 병목

1. 작가 에이전트 호출이 비용과 시간을 가장 크게 차지합니다.
2. 검토 에이전트 호출 수가 작가 에이전트보다 많아질 수 있습니다.
3. 높은 점수를 받은 후보도 선택 후 충돌에서 거절되어 전체 재작성으로 이어질 수 있습니다.
4. 캐시는 생성되고 있으나, 캐시 생성 자체가 비용 절감을 보장하는지 별도 확인이 필요합니다.
5. 비성공 호출이 재시도 루프와 함께 누적됩니다.

AX팀 검토 요청 사항

- 이 정도 형태의 비식별 패킷이면 비용/응답 지연 분석에 충분한가?
- 추가로 필요한 호출 단위 필드는 무엇인가?
- 선택 후 충돌을 원고 생성 전 또는 더 짧은 점검으로 옮길 수 있는가?
- 작가 에이전트와 검토 에이전트의 모델/토큰 예산을 분리하는 것이 적절한가?
- 캐시 생성/적중/건너뛸만으로 비용상 이득을 판단할 수 있는가?