

Vertex 청구 대조 요청표

이 문서는 로컬 추정 비용과 실제 Vertex 청구 데이터가 어느 정도 일치하는지 확인하기 위한 요청표입니다.

현재 문서의 비용은 로컬 llm_calls 집계에서 산출한 추정값입니다. 집계 원천은 projects/0_카나리아/project_data.db의 llm_calls이며, stage = 4, ep_num = 1..15 기준입니다. 실제 과금 정책, 캐시 토큰 과금, preview 모델 가격/쿼터, 저장 비용은 AX팀 또는 GCP/Vertex 청구 기준으로 확인이 필요합니다.

현재 로컬 Stage4 집계

집계 기준:

- 원본 DB: `projects/0\_카나리아/project\_data.db`
- 기준 테이블/필터: `llm\_calls where stage = 4`
- 회차 범위: `ep\_num = 1..15` (감독형 카나리아 15화 초안 연쇄)
- 포함 역할: `chief\_writer`, `director`, `manager`, `state\_extractor`
- 비용 성격: 로컬 런타임 추정치이며 Vertex 청구 원장이 아님

항목	값
Stage4 LLM 호출 수	653
입력 토큰	13,402,078
출력 토큰	1,566,917
캐시 토큰	6,987,784
로컬 추정 비용	약 USD 24.40
평균 호출 소요	48.8초

역할별 주요 집계

아래 표는 비용 비중이 큰 작가/검토 에이전트 중심 요약입니다. 총합에는 manager, state_extractor의 소량 호출도 포함되어 있습니다.

역할	모델	호출 수	총 토큰	로컬 추정 비용 USD	평균 소요	비성공
작가 에이전트	vertexai:gemini-3.1-pro-preview	269	8,878,731	16.017692	82.6초	17
검토 에이전트	vertexai:gemini-3.1-pro-preview	271	4,939,301	5.549227	20.5초	12
작가 에이전트	vertexai:gemini-2.5-pro	23	368,672	1.637426	64.8초	0
검토 에이전트	vertexai:gemini-2.5-pro	44	490,294	0.752089	27.4초	0

AX팀 확인 요청

확인 항목	현재 값 / 질문	AX팀 확인값
실제 Vertex 청구액	위 기간/호출 집계와 실제 청구가 어느 정도 일치하는가?	
preview 모델 단가	gemini-3.1-pro-preview 단가와 쿼터 정책은 무엇인가?	
정식 모델 단가	gemini-2.5-pro, gemini-2.5-flash 단가는 어떻게 다른가?	
캐시 입력 토큰 과금	캐시 토큰은 일반 입력 토큰과 다르게 과금되는가?	
캐시 생성 비용	캐시 생성 자체의 별도 비용이 있는가?	
캐시 저장/TTL 비용	저장 시간 또는 TTL에 따른 비용이 있는가?	
thinking/reasoning 토큰	별도 노출/과금되는가?	
count_tokens 사용	호출 전 토큰 계산이 비용 절감에 유리한가?	
API 지연 분해	API 자체 지연과 클라이언트 재시도/연속 생성 지연을 분리할 수 있는가?	

권장 대조 방식

1. 대조 기간을 하나로 고정합니다.
2. 해당 기간의 모델별 호출 수, 입력/출력/캐시 토큰, 추정 비용을 집계합니다.
3. Vertex 청구 데이터에서 같은 기간과 모델을 조회합니다.
4. preview 모델과 정식 모델을 분리합니다.
5. 캐시 토큰과 일반 입력 토큰의 과금 차이를 분리합니다.
6. 차이가 크면 로컬 비용 계산식, 모델 단가, 캐시 단가, thinking 토큰 처리 방식을 재검토합니다.

이 대조가 필요한 이유

- 지금은 로컬 추정 비용 기준으로 병목 우선순위를 세우고 있습니다.
- 실제 청구 구조가 다르면 최적화 우선순위가 달라질 수 있습니다.
- 특히 캐시 토큰이 비용을 얼마나 줄이는지 확인해야 캐시 정책을 확장할지 판단할 수 있습니다.