

## Vertex 청구 대조 요청표

이 문서는 로컬 추정 비용과 실제 Vertex 청구 데이터가 어느 정도 일치하는지 확인하기 위한 요청표입니다.

현재 문서의 비용은 로컬 llm\_calls 집계에서 산출한 추정값입니다. 실제 과금 정책, 캐시 토큰 과금, preview 모델 가격/쿼터, 저장 비용은 AX팀 또는 GCP/Vertex 청구 기준으로 확인이 필요합니다.

### 현재 로컬 Stage4 집계

| 항목              | 값           |
|-----------------|-------------|
| Stage4 LLM 호출 수 | 653         |
| 입력 토큰           | 13,402,078  |
| 출력 토큰           | 1,566,917   |
| 캐시 토큰           | 6,987,784   |
| 로컬 추정 비용        | 약 USD 24.40 |
| 평균 호출 소요        | 48.8초       |

### 역할별 주요 집계

| 역할      | 모델                              | 호출 수 | 총 토큰      | 로컬 추정 비용<br>USD | 평균 소요 | 비성공 |
|---------|---------------------------------|------|-----------|-----------------|-------|-----|
| 작가 에이전트 | vertexai:gemini-3.1-pro-preview | 269  | 8,878,731 | 16.017692       | 82.6초 | 17  |
| 검토 에이전트 | vertexai:gemini-3.1-pro-preview | 271  | 4,939,301 | 5.549227        | 20.5초 | 12  |
| 작가 에이전트 | vertexai:gemini-2.5-pro         | 23   | 368,672   | 1.637426        | 64.8초 | 0   |
| 검토 에이전트 | vertexai:gemini-2.5-pro         | 44   | 490,294   | 0.752089        | 27.4초 | 0   |

### AX팀 확인 요청

| 확인 항목         | 현재 값 / 질문                       | AX팀 확인값 |
|---------------|---------------------------------|---------|
| 실제 Vertex 청구액 | 위 기간/호출 집계와 실제 청구가 어느 정도 일치하는가? |         |

| 확인 항목                 | 현재 값 / 질문                                      | AX팀 확인값 |
|-----------------------|------------------------------------------------|---------|
| preview 모델 단가         | gemini-3.1-pro-preview 단가와 쿼터 정책은 무엇인가?        |         |
| 정식 모델 단가              | gemini-2.5-pro , gemini-2.5-flash 단가는 어떻게 다른가? |         |
| 캐시 입력 토큰 과금           | 캐시 토큰은 일반 입력 토큰과 다르게 과금되는가?                    |         |
| 캐시 생성 비용              | 캐시 생성 자체의 별도 비용이 있는가?                          |         |
| 캐시 저장/TTL 비용          | 저장 시간 또는 TTL에 따른 비용이 있는가?                      |         |
| thinking/reasoning 토큰 | 별도 노출/과금되는가?                                   |         |
| count_tokens 사용       | 호출 전 토큰 계산이 비용 절감에 유리한가?                       |         |
| API 지연 분해             | API 자체 지연과 클라이언트 재시도/연속 생성 지연을 분리할 수 있는가?      |         |

## 권장 대조 방식

- 대조 기간을 하나로 고정합니다.
- 해당 기간의 모델별 호출 수, 입력/출력/캐시 토큰, 추정 비용을 집계합니다.
- Vertex 청구 데이터에서 같은 기간과 모델을 조회합니다.
- preview 모델과 정식 모델을 분리합니다.
- 캐시 토큰과 일반 입력 토큰의 과금 차이를 분리합니다.
- 차이가 크면 로컬 비용 계산식, 모델 단가, 캐시 단가, thinking 토큰 처리 방식을 재검토합니다.

## 이 대조가 필요한 이유

- 지금은 로컬 추정 비용 기준으로 병목 우선순위를 세우고 있습니다.
- 실제 청구 구조가 다르면 최적화 우선순위가 달라질 수 있습니다.
- 특히 캐시 토큰이 비용을 얼마나 줄이는지 확인해야 캐시 정책을 확장할지 판단할 수 있습니다.